

Présentation du stage — Copilote IA Juridique pour TOP-JURIDIQUE

Stagiaire : Hichem Mhadhbi
Sujet : Prototype de copilote IA d'analyse de documents juridiques
Point principal : comment l'outil aide le **formaliste** au quotidien

1. Le pitch en 30 secondes

L'outil développé est un **copilote d'analyse de dossiers juridiques** : il prend en entrée les documents d'une société (pacte d'associés, statuts, contrats...), extrait les informations clés, applique **19 règles de contrôle juridique**, compare les documents entre eux, puis génère un **rapport de contrôle professionnel** qui liste les contradictions, les clauses manquantes et les risques, chacun expliqué, **sourcé (Légifrance/PISTE)** et accompagné d'une correction recommandée.

La décision finale reste toujours au **formaliste** : l'outil signale, il ne décide pas.

2. L'utilité pour le formaliste (l'essentiel de la demande)

2.1 Le rôle du formaliste, et ses difficultés

Le formaliste prépare et vérifie les actes avant leur dépôt (greffe, RCS, INPI) : il doit s'assurer que les documents d'un dossier sont **complets, cohérents entre eux** et **conformes** aux règles de droit. Ses difficultés quotidiennes :

- **Relire manuellement** des dizaines de pages (pacte, statuts, PV) à la recherche d'incohérences ;
- **Croiser deux documents** (pacte vs statuts) pour vérifier qu'ils disent la même chose ;
- **Repérer les clauses manquantes** avant qu'un tiers ou un refus de dépôt ne les mette en évidence ;
- **Gérer sa responsabilité professionnelle** : une incohérence non détectée peut être reprochée.

2.2 Ce que l'outil apporte concrètement

Bénéfice	Exemple concret
Gain de temps	Analyse complète d'un pacte + statuts en quelques minutes au lieu d'une relecture manuelle de plusieurs heures
Contradictions détectées	Un droit de veto présent dans le pacte mais absent des statuts → alerté immédiatement
Complétude du dossier	Détection des documents manquants (ex. : statuts absents d'un dossier de société)
Risques identifiés et priorisés	3 niveaux : bloquant (à corriger avant action), important , alerte
Chaque point est sourcé	Chaque anomalie cite sa base juridique (Code de commerce, Code civil) avec lien Légifrance — aucune référence inventée

Corrections suggérées	Pour chaque anomalie : une rédaction/action correctrice recommandée
Traçabilité totale	Rapport professionnel exportable en PDF, conversation avec le document, historique
Maîtrise humaine	Chaque anomalie doit être validée, modifiée ou rejetée par le professionnel — le formaliste garde la main

2.3 Le bénéfice de confiance

Pour un formaliste, la valeur n'est pas seulement le temps gagné : c'est la **réduction du risque d'erreur** et donc du **risque de responsabilité professionnelle**. L'outil agit comme un **deuxième jeu d'yeux systématique et exhaustif** qui ne se fatigue pas — tout en laissant le professionnel décider en dernier ressort.

3. Ce que fait l'outil — le pipeline en 7 étapes

Comme une chaîne de montage :

1. INGESTION → lecture des fichiers (PDF natif, PDF scanné via OCR, Word, images, texte)
2. CLASSIFICATION → deviner le type de document (pacte, statuts, autre) + signaler les documents manquants
3. EXTRACTION → trouver les dates, montants, parties, références d'articles, clauses
4. COMPARAISON → croiser 2 documents (pacte vs statuts) et relever les incohérences
5. RÈGLES → appliquer 19 règles de contrôle juridique déterministes
6. BASE JURIDIQUE (RAG-lite) → rattacher chaque anomalie aux articles et règles pertinents
7. RAPPORT → générer le rapport final (KPI, anomalies, incohérences, risque global, export PDF)

Les formats gérés

PDF natif, PDF scanné (OCR Tesseract en français), Word (.docx/.doc), images (PNG/JPG/JPEG), texte (.txt).

Les 3 niveaux de priorité des anomalies

Priorité	Signification
Bloquant	Le document est incomplet ou contraire à une règle — à corriger avant toute action
Important	Risque juridique réel à traiter
Alerte	Point de vigilance à vérifier

4. Les 19 règles de contrôle (le cœur métier)

13 règles de risques immédiats

1. Clause d'agrément absente ou incomplète
2. Clause de sortie d'associé
3. Droit de veto
4. Majorités de décision
5. Clause de non-concurrence

6. Contradiction pacte / statuts

7. Clause de blocage de la société
8. Pouvoirs du gérant / responsabilité
9. PV : quorum
10. PV : résolutions
11. Modification statutaire
12. Champs à compléter (information manquante)
13. Formulations et forme

6 règles de risques futurs (anticipation)

14. Valorisation des titres en cas de sortie
15. Décès ou incapacité d'un associé (aucune clause prévue)
16. Non-paiement (impayé) d'un associé
17. Confidentialité / secret des affaires
18. Résiliation : durée sans issue possible
19. Déséquilibre de gouvernance

Les règles sont **déterministes** (pas du hasard) : le même document donne toujours le même résultat, chaque alerte est explicable ligne par ligne.

5. Fiabilité juridique : la base de connaissances

- **Base locale structurée** : 18 entrées réelles (10 droit des sociétés / Code de commerce + 8 pactes d'associés / Code civil), chacune avec article, version, dates de vigueur, mots-clés et règles de contrôle associées.
- **RAG-lite** : à chaque analyse, les entrées pertinentes sont **réellement interrogées** et citées dans le rapport (chiffre affiché).
- **Vérification officielle Légifrance / PISTE** : le service obtient un jeton OAuth2 et vérifie chaque référence ou renvoie un lien de recherche officiel.
- **Anti-hallucination** : le système **n'invente jamais** de référence juridique. Sans source fiable, il le dit explicitement.

6. Démo pas à pas (à présenter en direct)

Préparation

1. Ouvrir l'application : version locale (`streamlit run app.py`) **ou** version en ligne (URL Render).
2. Préparer les documents d'exemple :
 - **Dossier de démonstration** : `livrables_stage/documents_exemple/pacte_associes_sarl.pdf` + `statuts_sarl.pdf`
 - **Dossier réel** (plus riche) : `analyse_reel/entrees/2B_MANAGEMENT/Pacte.pdf` + `Statuts.pdf`

Déroulé (environ 10 minutes)

Étape	Action	Ce qu'on montre
1	Déposer les 2 fichiers dans l'interface	Le multi-format : PDF, Word, images acceptés

2	Cliquer « Analyser le dossier »	Le pipeline tourne en quelques secondes
3	Regarder les KPI	Niveau de risque global, nombre d'anomalies, d'incohérences
4	Tableau Documents analysés	Types détectés automatiquement + documents manquants signalés
5	Informations clés	Dates, parties, montants extraits automatiquement
6	Cartes Anomalies	Badge de priorité + explication + source + correction recommandée
7	Cartes Incohérences	Contradictions pacte/statuts avec sévérité
8	Ouvrir la Synthèse intelligente (si clé IA configurée)	Résumé argumenté de l'analyse
9	Poser une question au chatbot	Ex. : « Quel est le droit de veto prévu ? », « Quels sont les risques bloquants ? »
10	Exporter le rapport PDF	Le document professionnel remis au client / versé au dossier

Les phrases à dire à l'étape 6

« Ici, le système a détecté que la clause X du pacte n'est pas reprise dans les statuts. C'est une contradiction importante : elle est expliquée, sourcée (article de loi) et accompagnée d'une correction suggérée. C'est exactement le type de point qui peut poser problème au dépôt, ou être utilisé contre le client plus tard. »

7. Le travail réalisé pendant le stage

Cheminement semaine par semaine

Semaine	Travail effectué
1-2	Compréhension de la mission, benchmark de 18 solutions legaltech, définition du cas d'usage, choix techniques, architecture
3-4	Module d'ingestion multi-format + OCR, module d'extraction, création de la base juridique, moteur de 19 règles
5-6	Comparaison inter-documents (pacte vs statuts), RAG-lite, génération de rapport, interface Streamlit
7	API REST, module de validation humaine, 164 tests automatisés, tests sur dossiers réels
8	Déploiement (Render), documentation, démonstration, livrables

Les 17 points de la mission — tous traités

- 1. Compréhension de la mission et de l'écosystème legaltech
- 2. Traitement multi-format (PDF natif, scanné, Word, images, illisible, OCR)
- 3. Analyse des documents juridiques
- 4. Comparaison et détection de contradictions
- 5. Détection des risques (19 règles, dont 6 risques futurs)
- 6. Sources fiables et vérifiables (Légifrance, PISTE — jamais de référence inventée)
- 7. Base juridique structurée et interrogée (RAG-lite)
- 8. Rapport d'analyse clair et structuré
- 9. Export multi-formats (PDF, Markdown, JSON, texte)
- 10. Benchmark des solutions IA / legaltech (18 outils analysés)
- 11. Architecture technique modulaire (10 couches séparées)
- 12. Intégration TOP-JURIDIQUE (API REST documentée)
- 13. Cas d'usage : pacte d'associés comparé aux statuts
- 14. Validation juridique (process de validation humaine)
- 15. Livrables complets (code, base juridique, rapport, docs, tests)
- 16. Documentation et ressources officielles
- 17. Benchmark et suivi

Chiffres clés du travail

Indicateur	Valeur
Lignes de code Python	~6 700 (30+ fichiers)
Tests automatisés	164, tous verts
Règles de contrôle	19 (dont 6 risques futurs)
Entrées base juridique	18, réellement interrogées
Formats de fichiers	6 (PDF, PDF scanné, Word, images, texte)
Fournisseurs IA	3 (Groq, Google AI, OpenRouter) avec repli local
Exports	4 (PDF, Markdown, JSON, texte)
Dossiers de démo réels analysés	6 (SARL et SAS)

8. Architecture en une page (vue simplifiée)

PRESENTATION

CLI (main.py) | Interface web Streamlit (app.py) | API REST FastAPI (api/)

■

ORCHESTRATION → services/analysis_service.py (le pipeline en 7 étapes)

■

INGESTION → lecture multi-format + OCR des PDF scannés

EXTRACTION → dates, montants, parties, clauses

COMPARAISON → croisement pacte / statuts

RÈGLES → 19 règles déterministes (rules_engine/)

BASE JURIDIQUE → legal_kb/ (18 entrées) + RAG-lite + Légifrance/PISTE

RAPPORT → report_generator/ (Markdown, PDF, JSON)

- 3 façons d'utiliser l'outil :**
- 1. **Interface web** (Streamlit) : déposer des fichiers, analyser, lire le rapport, poser des questions ;
 - 2. **Ligne de commande** (CLI) : analyser un dossier de PDF sans interface ;
 - 3. **API REST** (FastAPI) : prête à être intégrée dans la plateforme TOP-JURIDIQUE.

9. Limites honnêtes et suites possibles

Limites actuelles du prototype

- 1. **Base juridique réduite** : 18 entrées couvrent le droit des sociétés et les pactes ; à étendre (PV, contrats, baux).
- 2. **Extraction par règles** (regex) : robuste mais pas encore du NLP avancé (spaCy, CamemBERT en cours d'évaluation).
- 3. **Intégration TOP-JURIDIQUE** : l'API est prête, mais l'accès à l'environnement de test reste à fournir.
- 4. **OCR sur le cloud** : l'OCR Tesseract n'est pas installé sur l'hébergement Render (les PDF scannés y sont signalés, l'OCR complet fonctionne en local).
- 5. **Clés IA optionnelles** : sans clé, l'outil fonctionne à 100 % en local ; l'IA enrichit (synthèse, analyse de clauses) quand une clé est configurée.

Suites possibles

- 1. Connecter la plateforme TOP-JURIDIQUE à l'API (phase d'intégration).
- 2. Étendre la base juridique et les règles aux autres types de documents (PV, modifications statutaires, contrats).
- 3. NLP avancé pour l'extraction de clauses.
- 4. Dashboard juridique de validation (tableau de bord des dossiers).
- 5. Recherche vectorielle (embeddings + FAISS) en extension du RAG-lite.

10. Où trouver chaque chose

Contenu	Emplacement
Rapport d'exemple généré	livrables_stage/rapport_exemple/rapport_analyse.pdf
Documents de démo	livrables_stage/documents_exemple/
Analyse complète du travail	livrables_stage/analyse_complete_travail.md
Benchmark des solutions	livrables_stage/benchmark_solutions_ia.md
Documentation mission & architecture	docs/01...06
Code source + tests	racine du projet (app.py, main.py, services/, rules_engine/, tests/)
Démo en ligne	URL Render (https://top-juridique-copilote-iqgi.onrender.com)